

MÁSTER EN BIG DATA, DATA SCIENCE E INTELIGENCIA ARTIFICIAL
Universidad Complutense de Madrid

PROPUESTA DE TRABAJO FIN DE MÁSTER

*Predicción del riesgo de readmisión hospitalaria en pacientes diabéticos:
un enfoque de machine learning aplicado a la mejora de la calidad asistencial*

Opción elegida: 1 — Análisis de un dataset (orientación Data Scientist)
Tutores: Carlos Ortega y Santiago Mota

Lucía Ballina Muñoz
Agosto 2026

Índice

1. Introducción y motivación	3
2. Descripción del dataset	3
3. Análisis exploratorio de datos (EDA)	4
• Análisis descriptivo univariante y bivariante	
• Distribución de la variable objetivo (desbalanceo de clases)	
• Relación entre variables clínicas/demográficas y readmisión	
• Detección de valores ausentes, outliers e inconsistencias	
4. Preparación y transformación de datos	5
• Tratamiento de valores faltantes	
• Codificación de variables categóricas	
• Tratamiento del desbalanceo de clases	
• Feature engineering	
5. Modelización	6
• Planteamiento del problema	
• Modelos evaluados y justificación	
• Métricas de evaluación	
• Comparativa de resultados	
• Valor añadido frente a un AutoML	
6. Interpretabilidad del modelo	8
7. Productivización	9
8. Conclusiones y líneas futuras	10
9. Bibliografía	11

Anexos (no computan en las 20 caras)

- Anexo I — Código completo (notebook Jupyter)
- Anexo II — EDA detallado con salidas extensas
- Anexo III — Resultados completos de todos los modelos probados

Descripción del TFM

Base de datos propuesta

Diabetes 130-US Hospitals for Years 1999-2008 — UCI Machine Learning Repository.

Fuente: archive.ics.uci.edu/dataset/296

El conjunto representa diez años (1999-2008) de atención clínica en 130 hospitales y redes de asistencia sanitaria de Estados Unidos. Cada registro corresponde a un ingreso hospitalario de un paciente diagnosticado de diabetes, con pruebas de laboratorio, medicación administrada y estancias de hasta 14 días. Incluye aproximadamente 101.000 registros y 50 variables (demografía del paciente, tipo de ingreso, especialidad médica, diagnósticos codificados en ICD-9, resultados de laboratorio, medicación y utilización previa de servicios sanitarios). La variable objetivo indica si el paciente fue readmitido en el hospital antes de 30 días desde el alta.

Justificación de la elección

- Tamaño y complejidad: más de 100.000 filas y 50 variables, con retos de limpieza (valores ausentes, alta cardinalidad, codificaciones clínicas).
- Caso de negocio: reducir reingresos hospitalarios tiene impacto directo en costes y calidad asistencial.
- Se presta a un desarrollo completo de modelización (varias familias de algoritmos), interpretabilidad y productivización.
- Licencia abierta (CC BY 4.0), sin restricciones de uso ni necesidad de NDA.

Resumen del planteamiento

El trabajo abordará el análisis del dataset descrito con el objetivo de construir un modelo predictivo capaz de estimar la probabilidad de que un paciente diabético reingrese en el hospital dentro de los 30 días posteriores al alta. Tras una fase de análisis exploratorio y limpieza exhaustiva, se compararán distintas técnicas de modelización (por ejemplo, regresión logística, Random Forest y Gradient Boosting), justificando en cada caso su idoneidad, ventajas y limitaciones frente a las demás. Se dará especial relevancia a la interpretabilidad de los resultados (mediante técnicas como SHAP) para poder comunicar los factores de riesgo relevantes a un perfil de negocio no técnico. El trabajo cerrará con una propuesta de productivización del modelo —simulando su exposición como servicio que reciba los datos de un nuevo ingreso y devuelva una predicción de riesgo— y un apartado final de conclusiones y líneas de mejora futuras.

Entregables previstos

- Memoria (documento, máx. 20 caras): el presente documento desarrollado según el índice anterior.
- Vídeo (máx. 5 minutos, formato MP4, ≤ 50 Mb) explicando enfoque, conclusiones y lecciones aprendidas.
- Anexos: código (notebook Jupyter) y estudios preliminares (EDA detallado, resultados de todos los modelos).